

SLM Assignment: Fine-Tuning for English–Hindi Translation

Hardware: NVIDIA P100 GPU

Memory: 16GB VRAM

Framework: Hugging Face Transformers

Runtime: Kaggle Notebook

Built by - Deepanshu Miglani

a) Model Architecture

Model: IndicTrans2 (ai4bharat/indictrans2-en-indic-dist-200M)

Type: Transformer-based Encoder-Decoder

Parameters: 200M

Languages: English ↔ Indic (Hindi)


The model used in this assignment is IndicTrans2, a Transformer-based sequence-to-sequence model developed by AI4Bharat. It follows an encoder–decoder architecture, where the encoder processes the source English text and the decoder generates the corresponding Hindi translation token by token.

IndicTrans2 is a distilled multilingual model with approximately 200 million parameters, making it suitable for Small Language Model (SLM) requirements. The model uses subword tokenization and requires explicit source and target language tags to guide translation between languages.

During inference, different decoding strategies such as beam search and sampling-based decoding are applied to control translation quality and diversity.

IndicTrans2 (200M) Architecture

Fine-Tuned on IIT Bombay Corpus



b) Approach

Method: Fine-tune IndicTrans2 on IIT Bombay dataset

Optimizer: AdamW | Learning Rate: 1e-5

Batch Size: 4 | Gradient Accumulation: 16 steps

Epochs: 4 (with early stopping)

Validation Split: Monitor on validation set

A **fine-tuning approach** was adopted using a pretrained IndicTrans2 model instead of training a model from scratch. This approach was chosen because IndicTrans2 already contains strong multilingual representations learned from large-scale data.

Fine-tuning allows the model to adapt specifically to the **English–Hindi translation task** using a smaller dataset and limited computational resources, while still achieving good translation quality. This approach is efficient, practical, and well-suited for the scope of this assignment.

c) Dataset

Dataset-Statistics

Language	Train	Valid	Test
En-Hi	50000	520	2500
Total			53320

Dataset- <https://huggingface.co/datasets/cfilt/iitb-english-hindi>

The **IIT Bombay English–Hindi dataset** was used for training, validation, and evaluation. This dataset consists of parallel English–Hindi sentence pairs and is widely used as a benchmark for machine translation tasks involving Indian languages.

The dataset was divided into:

- **Training set** for model fine-tuning
- **Validation set** for monitoring performance and early stopping
- **Test set** for final evaluation

e) Evaluation Metrics

Metric	Baseline Model	Fine-Tuned	Improvement
BLEU	21.83	22.72	+0.89
ROUGE-1	0.1645	0.1667	+0.0022
ROUGE-2	0.0452	0.0525	+0.0073
ROUGE-L	0.1608	0.1620	+0.0012

All metrics were computed on the IIT Bombay English–Hindi test set.

Testing the model on different temperatures, top_k and top_p values)

1 to 5 of 5 entries Filter								
index	Sentence_ID	Source_Text	Config_ID	Temperature	Top_k	Top_p	Generated_Translation	
0	1	Artificial Intelligence is transforming healthcare.	1	0.7	50	0.9	आर्टिफिशियल इंटेलिजेंस स्वास्थ्य सेवा को बदल रहा है.	
1	1	Artificial Intelligence is transforming healthcare.	2	1.0	50	0.9	कृत्रिम बुद्धिमत्ता स्वास्थ्य सेवा को बदल रही है.	
2	1	Artificial Intelligence is transforming healthcare.	3	1.2	50	0.9	आर्टिफिशियल इंटेलिजेंस द्वारा स्वास्थ्य देखभाल में बदलाव किया जा रहा है/आपनिक प्रबंधन	
3	1	Artificial Intelligence is transforming healthcare.	4	1.0	30	0.8	आर्टिफिशियल इंटेलिजेंस स्वास्थ्य सेवाओं में बदलाव ला रहा है.	
4	1	Artificial Intelligence is transforming healthcare.	5	1.0	0	1.0	आर्टिफिशियल इंटेलिजेंस स्वास्थ्य सेवा में परिवर्तन कर रहा है -व कोरो ۱۹/بجاوا: کورس۱۹.	

Detailed pdf file attached to github repository

Human-Evaluation
(adequacy, fluency, overall)

source_english	reference_hindi	predicted_hindi	Adequacy_Score	Fluency_Score	Overall_Score	Comment
A black box in your car?	आपकी कार में ब्लैक बॉक्स?	आपकी कार में एक ब्लैक बॉक्स	4	4	4	4 Missing question mark, but meaning preserved well.
As America's road planners struggle to find the	जबकि अमेरिका के सड़क योजनाकार, ध्वस्त होते हुए हाईवे सि जैसे ही अमेरिका के सड़क योजनाकार एक जर्जर राजमार्ग प्रणाली	जबकि अमेरिका के सड़क योजनाकार, ध्वस्त होते हुए हाईवे सि जैसे ही अमेरिका के सड़क योजनाकार एक जर्जर राजमार्ग प्रणाली	4	4	4	4 Good meaning but slightly awkward phrasing with periods.
The devices, which track every mile a motorist	यह डिवाइस, जो मोटर-वाहक द्वारा वाहन चलाए गए प्रत्येक एक मोटर वाहक द्वारा चलाए जाने वाले हर मील का पता लगा	यह डिवाइस, जो मोटर-वाहक द्वारा वाहन चलाए गए प्रत्येक एक मोटर वाहक द्वारा चलाए जाने वाले हर मील का पता लगा	5	5	5	5
The usually dull arena of highway planning has	आम तौर पर हाईवे नियोजन जैसा उबाऊ काम भी अचानक गहन राजमार्ग नियोजन के सामान्य रूप से सुस्त क्षेत्र ने अचानक तीव्र	आम तौर पर हाईवे नियोजन जैसा उबाऊ काम भी अचानक गहन राजमार्ग नियोजन के सामान्य रूप से सुस्त क्षेत्र ने अचानक तीव्र	5	4	4	4 Minor word choice differences, meaning intact.
Libertarians have joined environmental groups	आपने द्वारा झुड़व किए गए मौल, तथा संभवतः झुड़व किए गए लिबर्टेरियन पर्यावरण समूहों के साथ लोकिय में शामिल हो गए।	आपने द्वारा झुड़व किए गए मौल, तथा संभवतः झुड़व किए गए लिबर्टेरियन पर्यावरण समूहों के साथ लोकिय में शामिल हो गए।	5	5	5	5
The tea party is agast.	चाय पार्टी भीचकी है।	चाय की पार्टी चीक देती है.	4	4	4	4 Meaning preserved, slight word order awkwardness.
The American Civil Liberties Union is deeply cor	अमेरिकी नागरिक स्वतंत्रता संघ भी विभिन्न प्रकार के गोपनीय अमेरिकन सिविल लिबर्टीज यूनियन भी गोपनीयता के विभिन्न	अमेरिकी नागरिक स्वतंत्रता संघ भी विभिन्न प्रकार के गोपनीय अमेरिकन सिविल लिबर्टीज यूनियन भी गोपनीयता के विभिन्न	2	2	2	2 Incorrect meaning - translates "agast" wrong.
And while Congress can't agree on whether to	जबकि कांग्रेस इस बात पर सहमत नहीं हो सकी कि आगे की क जबकि कांग्रेस इस बात पर सहमत नहीं हो सकती कि आगे बढन	जबकि कांग्रेस इस बात पर सहमत नहीं हो सकी कि आगे की क जबकि कांग्रेस इस बात पर सहमत नहीं हो सकती कि आगे बढन	5	5	5	5
They are exploring how, over the next decade,	वे यह खोज कर रहे हैं कि अगले दशक में वे किस तरह से ऐसी प्र वे इस बात की खोज कर रहे हैं कि कैसे अगले दशक में वे एक ऐ	वे यह खोज कर रहे हैं कि अगले दशक में वे किस तरह से ऐसी प्र वे इस बात की खोज कर रहे हैं कि कैसे अगले दशक में वे एक ऐ	4	4	4	4 Good, uses "सकती" instead of "सकी", minor tense shift.
Thousands of motorists have already taken the	हजारों मोटर-वाहकों ने ट्रस्ट झुड़व के लिए पहले ही ब्लैक बॉक्स हजारों मोटर वाहकों ने पहले ही परीक्षण झुड़व के लिए ब्लैक बॉ	हजारों मोटर-वाहकों ने ट्रस्ट झुड़व के लिए पहले ही ब्लैक बॉक्स हजारों मोटर वाहकों ने पहले ही परीक्षण झुड़व के लिए ब्लैक बॉ	5	4	4	4 Good preservation, slightly awkward phrasing.
This really is a must for our nation.	यह हमारे देश के लिए वास्तव में अनिवार्य वस्तु है।	यह वास्तव में हमारे देश के लिए आवश्यक है.	5	4	4	4 Minor period addition, meaning intact.
"It is not a matter of something we might choo	"यह हमारे द्वारा चुने या नहीं चुने जाने का विषय नहीं है" यह क स्टर्न कैलिफोर्निया एसोसिएशन ऑफ गवर्नमेंट्स के कार्यकारी	"यह हमारे द्वारा चुने या नहीं चुने जाने का विषय नहीं है" यह क स्टर्न कैलिफोर्निया एसोसिएशन ऑफ गवर्नमेंट्स के कार्यकारी	5	5	5	5
There is going to be a change in how we pay th	हमारे द्वारा कर भुगतान किए जाने के तरीके में परिवर्तन होने : हम इन करों के भुगतान के तरीके में बदलाव करने जा रहे हैं.	हमारे द्वारा कर भुगतान किए जाने के तरीके में परिवर्तन होने : हम इन करों के भुगतान के तरीके में बदलाव करने जा रहे हैं.	3	3	3	3 Missing quote framing, incomplete sentence structure.
The technology is there to do it.	ऐसा करने के लिए ज़रूरत है।	ऐसा करने के लिए तकनीक मौजूद है.	4	4	4	4 Missing quote but meaning conveyed.
The push comes as the country's Highway Trust	ऐसा होने का मुख्य कारण यह है कि देश का हाईवे ट्रस्ट फंड लग दबाव तब आता है जब गैस पंप पर अमेरिकियों द्वारा भुगतान	ऐसा होने का मुख्य कारण यह है कि देश का हाईवे ट्रस्ट फंड लग दबाव तब आता है जब गैस पंप पर अमेरिकियों द्वारा भुगतान	5	5	5	5
Americans don't buy as much gas as they used	अमेरिकी लोग अब पहले जितनी गैस नहीं खरीदते।	अमेरिकी लोग उमनी गैस नहीं खरीदते जितनी वे पहले खरीदते	4	3	3	3 Weakly translated "is broke" - awkward rendering.
Cars get many more miles to the gallon.	अब एक गैलन गैस में कार पहले से अधिक मील चलती है।	कारें गैलन तक कई मील की दूरी तय करती हैं.	4	4	4	4 Good translation, proper meaning.

Detailed PDF file attached to the Github repository

Conclusion & Future Work

Summary:

- Successfully fine-tuned IndicTrans2 on IIT Bombay dataset
- Achieved measurable improvements in BLEU and ROUGE metrics
- Demonstrated effective use of decoding strategies (Temperature, Top-K, Top-P)
- Model shows strong performance on instruction-following and context awareness

Future Work:

- Explore larger training datasets for enhanced performance
- Implement multi-task learning with back-translation
- Extend to other Indian language pairs
- Deploy model as a production service with an API endpoint
- Conduct extensive human evaluation on diverse domains

The fine-tuned model can be accessed at:

https://huggingface.co/deepanshumiglani0408/indictrans2_finetune